Федеральное государственное автономное образовательное учреждение
высшего образования
«Национальный исследовательский университет «Высшая школа экономики»

Факультет компьютерных наук
Искусственный интеллект
(Название ОП)
магистратура
(уровень образования)

О Т Ч Е Т
по дисциплине «Временные ряды»
Влияние нормализации временных рядов на качество прогнозирования
(Название проекта)

Выполнил студент
Железнов
Кирилл
Игоревич
(ФИО)

Москва, 2026

Основная цель проекта - изучить влияние нормализации временных рядов на качество прогнозирования для моделей разных классов.

Гипотеза - нормализация по рядам особенно важна для глобальных нейронных моделей, но влияет неоднозначно для моделей из разных классов.

В ходе работы используются бейзлановые методы и глобальные модели. Используемые методы нормализации - StandardScaler, RobustScaler, QuantileTransformer.

Пайплайн:

- Загрузка и конвертация данных
- Выбор N рядов
- Обучение моделей с разными вариантами нормализации
- Оценка по метрикам
- Визуализация и анализ

Методология:

- Датасет M4 Monthly Dataset, отбор N=200 рядов

- Бейзлайны: Naive, SeasonalNaive, AutoETS, AutoTheta

- Глобальные модели: CatBoostRegressor, PatchTST

- Нормализация по рядам:

    - без нормализации

    - StandardScaler - удаляет среднее и масштабирует к единичной дисперсии

    - RobustScaler - использует медиану и квантили, благодаря чему устойчив к выбросам

    - QuantileTransformerScaler – преобразует распределение к равномерному или нормальному

- Метрики:

    - SMAPE - основная метрика, выбрана, так как она учитывает относительное отклонение и подходит для сравнения прогнозов с ряда с разными масштабами, что критично при анализе влияния нормализации по рядами

    - MAE и RMSE - дополнительные метрики, MAE показывает среднее абсолютное отклонение и легко интерпретируется, RMSE помогает оценить влияние редких и сильных выбросов на качество.

После запуска экспериментов были получены метрики, показанные в таблице ниже.

Модель	SMAPE	MAE	RMSE
AutoETS	3.4	661.82	1638.51
AutoTheta	3.35	626.77	1440.77
Naive	3.74	736.23	1614.13
SeasonalNaive	4.1	783.7	1638.15
CatBoostRegressor	3.81	730.9	1550.16
PatchTST	3.77	714.47	1508.53
AutoETS_Standard	3.35	615.75	1350.98
AutoTheta_Standard	3.46	646.53	1464.72
Naive_Standard	3.74	736.23	1614.13
SeasonalNaive_Standard	4.1	783.7	1638.15
CatBoostRegressor_Standard	3.81	730.9	1550.16
PatchTST_Standard	3.5	663.81	1449.62
AutoETS_Robust	3.41	617.53	1343.28
AutoTheta_Robust	3.43	641.12	1460.88
Naive_Robust	3.74	736.23	1614.13
SeasonalNaive_Robust	4.1	783.7	1638.15
CatBoostRegressor_Robust	3.81	730.9	1550.16
PatchTST_Robust	3.5	662.87	1448.02
AutoETS_QuantileTransformer	3.3	611.04	1382.08
AutoTheta_QuantileTransformer	3.26	628.18	1436.46
Naive_QuantileTransformer	3.74	736.23	1614.13
SeasonalNaive_QuantileTransformer	4.1	783.7	1638.15
CatBoostRegressor_QuantileTransformer	3.74	722.21	1553.25
PatchTST_QuantileTransformer	3.59	679.35	1464.61

На графиках ниже представлен ряд T19247 и предсказания для моделей Naive, CatBoostRegressor, PatchTST.

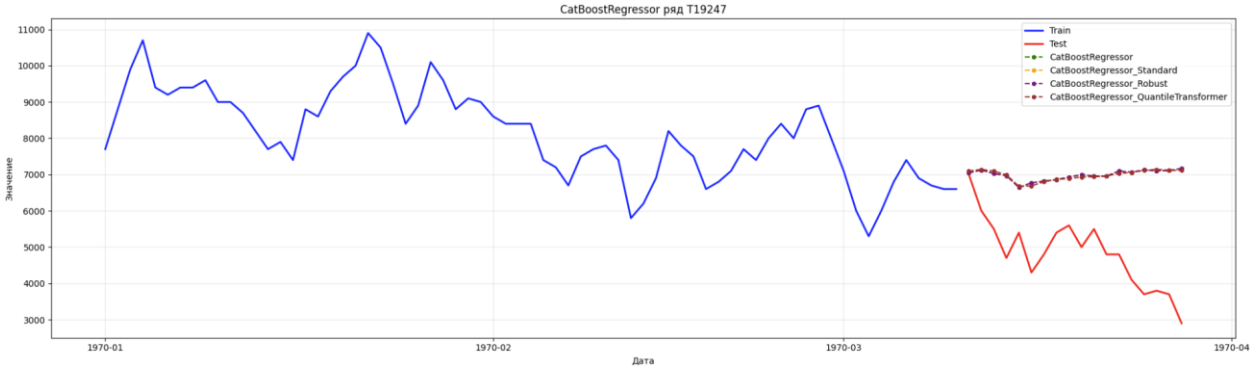

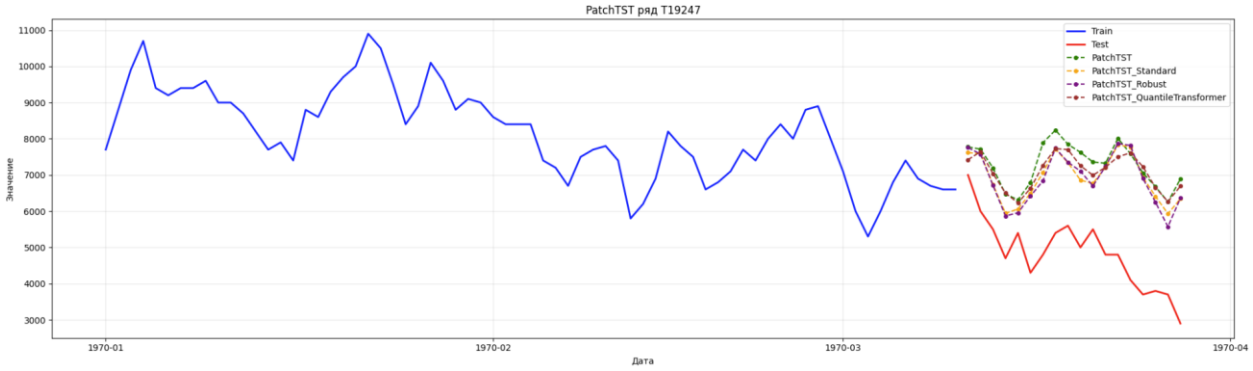

На графиках ожидаемое влияние нормализации. Naive не отличается вне зависимости от примененного метода нормализации. CatBoost имеет небольшие отличия, что показывает его умеренную чувствительность к нормализации. PatchTST имеет заметные различия в прогнозах, что подтверждает важность нормализации для него.

На графике ниже представлены значения метрики SMAPE для всех экспериментов для удобства сравнения (графики остальных метрик в ipynb-файле, так как результат похож).

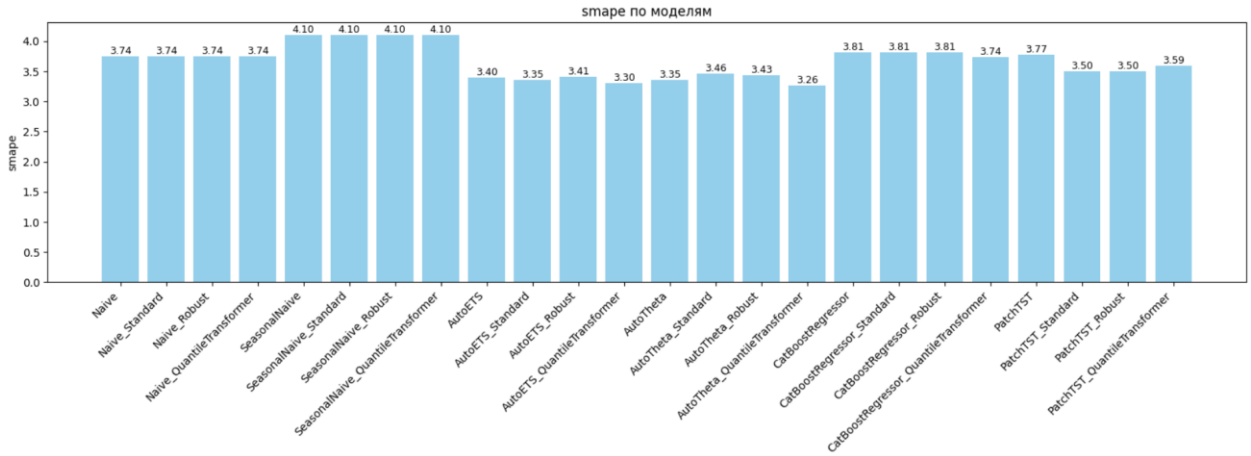

Из него видно, что Naive и SeasonalNaive никак не изменяются при применении нормализации. Однако AutoETS и AutoTheta показывают разнящиеся результаты в зависимости от применяемого метода нормализации, что показывает неоднозначное влияние на статистические методы. CatBoost практически не изменяется, что объясняется модели на основе деревьев не чувствительны к масштабу признаков, за исключением QuantileTransformerScaler. PatchTST существенно зависит от нормализации.

На графиках ниже представлены сравнения метрики SMAPE с применением нормализации и без применения для всех экспериментов для удобства сравнения (графики остальных метрик в ipynb-файле). Слева абсолютное сравнение, справа дельта между метриками без применения и с применением нормализации (положительное значение – негативное изменение).

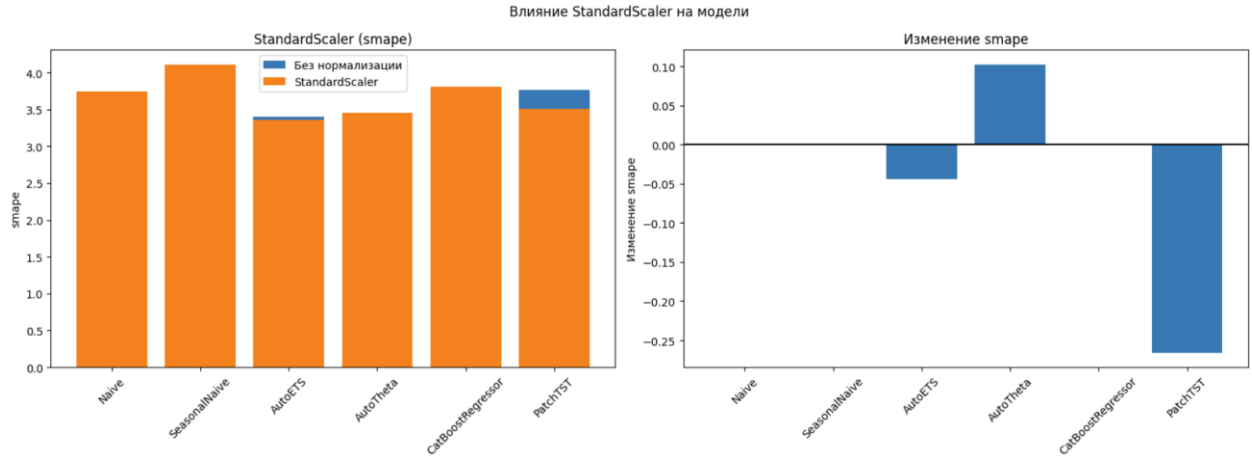

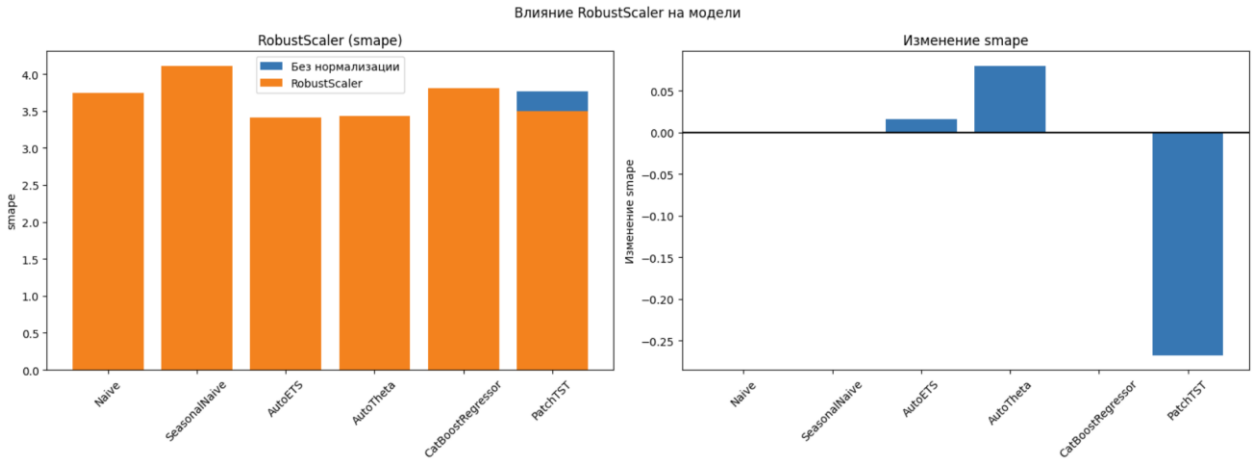

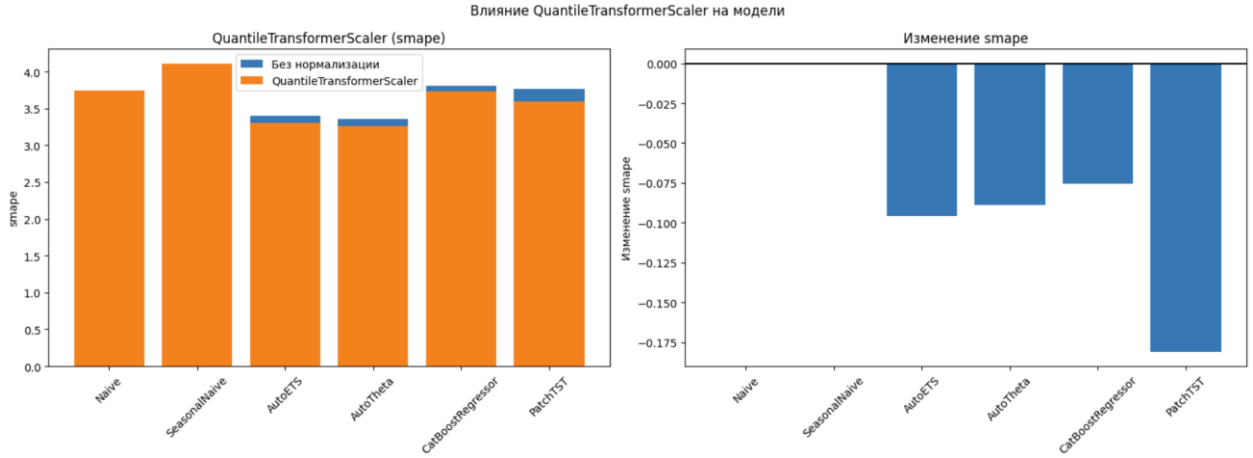

Данная визуализация более явно показала вывод сделанный выше. Однако эти графики показали большую зависимость CatBoost от QuantileTransformerScaler.

Выводы: В ходе выполнения данной работы было подтверждено влияние нормализации для глобальных нейронных моделей (PatchTST), в каждом эксперименте нормализация приводила к улучшению как основной метрики SMAPE, так и дополнительных. ML модель (CatBoost) в основном показала независимость от применяемой нормализации, за исключением QuantileTransformerScaler. Naive и SeasonalNaive показали полное отсутствие влияния нормализации на качество и прогноз. AutoETS и AutoTheta продемонстрировали нестабильную реакцию на нормализацию - некоторые эксперименты привели к улучшению метрик, другие к ухудшению, из-за чего нельзя однозначно подтвердить положительное или негативное влияние нормализации на них.